

隐马尔可夫模型(2)

(HMM)

徐静

2018-06-24

上节回顾

0.马尔可夫链

1.隐马尔可夫模型的基本概念

2.概率计算算法

3.参考文献

4.下次预告

5.问题与讨论

本节内容

1.学习算法

- 问题2的解决办法

2.预测算法

- 问题3的解决办法

3.HMM代码实现2

4.后退，我要实现一个GMM-HMM语音识别系统

- 放松一下: 看看我的偶像
- 愉快的读paper
- GMM-HMM语音识别系统
- 其他语音识别框架

5.参考文献与问题讨论

1.学习算法

已知观测序列 $O = (o_1, o_2, \dots, o_T)$, 估计模型 $\lambda = (A, B, \pi)$ 参数, 使得在该模型下观测序列概率 $\Pr(O|\lambda)$ 最大, 即用极大似然估计的方法估计参数。

HMM的学习, 根据训练数据是包括观测序列和对应的状态序列还是只有观测序列, 可以分别由监督学习与非监督学习实现。

本部分先介绍监督学习算法, 再介绍非监督学习算法--Baum-Welch算法 (也就是EM算法)

1.监督学习方法

假设已给的训练数据包含 S 个长度相同的观测序列和对应的状态序列 $\{(O_1, I_1), (O_2, I_2), \dots (O_s, I_s)\}$, 那么可以利用极大似然估计法来估计HMM的参数。

1.转移概率 a_{ij} 的估计

设样本中时刻 t 处于状态 i 时刻 $t + 1$ 转移至状态 j 的频数为 A_{ij} ,那么状态转移概率 a_{ij} 的估计是

$$\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}, i = 1, 2, \dots, N; j = 1, 2, \dots, N$$

2.观测概率 $b_j(k)$ 的估计

设样本中状态为 j 并观测为 k 的频数是 B_{jk} , 那么状态为 j 观测为 k 的概率 $b_j(k)$ 的估计是

$$\hat{b}_j(k) = \frac{B_{jk}}{\sum_{k=1}^M B_{jk}}, j = 1, 2, \dots, N; k = 1, 2, \dots, M$$

3.初始状态概率 π 的估计 $\hat{\pi}$ 为 S 个样本中初始状态为 q_i 的频率

由于监督学习需要使用训练数据，而人工标注训练数据往往代价很高，有时候就会利用非监督学习的方法

2.非监督学习算法--Baum-Welch算法

假设给定训练数据中包含 S 个长度为 T 的观测序列 $\{O_1, O_2, \dots, O_s\}$ 而没有对应的状态序列，目标是学习HMM模型 $\lambda = (A, B, \pi)$ 的参数。我们将观测序列数据看做观测数据 O ，状态序列看做不可观测的因数据 I ，那么HMM事实上是一个含有隐变量的概率模型

$$\Pr(O|\lambda) = \sum \Pr(O|I, \lambda) \Pr(I|\lambda)$$

参数学习可以由EM算法实现。

1.确定完全数据的对数似然函数

所有观测数据写成 $O = (o_1, \dots, o_T)$, 所有隐数据写成 $I = (i_1, \dots, i_T)$, 完全数据是 $(O, I) = (o_1, \dots, o_T, i_1, \dots, i_T)$. 完全数据的对数似然函数是 $\log \Pr(O, I|\lambda)$

2.EM算法的E步：求 Q 函数 $Q(\lambda, \bar{\lambda})$ [1]

$$Q(\lambda, \bar{\lambda}) = \sum_I \log \Pr(O, I|\lambda) \Pr(O, I|\bar{\lambda})$$

其中, λ 是HMM参数的当前估计值, $\bar{\lambda}$ 是要极大化的HMM参数。

$$\Pr(O, I|\lambda) = \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \dots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

于是函数 Q 可以写成：

$$Q(\lambda, \bar{\lambda}) = \sum_I \log \pi_{i_1} \Pr(O, I|\bar{\lambda}) + \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) \Pr(O, I|\bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) \Pr(O, I|\bar{\lambda})$$

式中求和都是对所有新联数据的序列总长度 T 进行的。

[1].按照 Q 函数的定义 $Q(\lambda, \bar{\lambda}) = E_I[\log \Pr(O, I|\lambda)|O, \bar{\lambda}]$

3. EM算法的M步: 极大化 Q 函数 $Q(\lambda, \bar{\lambda})$ 求模型参数 A, B, π

由于要极大化的参数分别出现在上式的3个独立部分, 所以只需要对各项分别极大化

第一项: 使用拉格朗日数乘法(注意约束条件: $\sum_{i=1}^N \pi_i = 1$), 最终可以得到

$$\pi_i = \frac{\Pr(O, i_1 = i | \bar{\lambda})}{\Pr(O | \bar{\lambda})}$$

第二项: 使用拉格朗日数乘法(注意约束条件: $\sum_{j=1}^N a_{ij} = 1$), 最终可以求得

$$a_{ij} = \frac{\sum_{t=2}^{T-1} \Pr(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} \Pr(O, i_t = i | \bar{\lambda})}$$

第三项: 同样使用拉格朗日数乘法(约束条件: $\sum_{k=1}^M b_j(k) = 1$)

$$b_j(k) = \frac{\sum_{t=1}^T \Pr(O, i_t = j | \bar{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T \Pr(O, i_t = j | \bar{\lambda})}$$

注意: 只有在 $o_t = v_k$ 时 $b_j(o_t)$ 对 $b_j(k)$ 的偏导数才不为0, 以 $I(o_t = v_k)$ 表示(这是当然了)

3.Baum-Welch模型参数估计

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}; b_j(k) = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}; \pi_i = \gamma_1(i)$$

负责人的告诉大家：上述三个式子就是Baum-Welch算法

Baum-Welch算法：

输入：观测数据 $O = (o_1, o_2, \dots, o_T)$

输出：隐马尔可夫模型参数

(1) 初始化

对 $n = 0$ 选取 $a_{ij}^{(0)}, b_j(k)^{(0)}, \pi_i^{(0)}$, 得到模型 $\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)})$

(2) 递推. 对 $n = 1, 2, \dots$, $a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}; b_j(k)^{(n+1)}; \pi_i^{(n+1)}$

右端各值按观测 $O = (o_1, o_2, \dots, o_T)$ 和模型 $\lambda^{(n)} = (A^{(n)}, B^{(n)}, \pi^{(n)})$ 计算

(3) 终止. 得到模型参数 $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$

2.预测算法

- 预测问题，也称为解码(decoding)问题,已知模型和观测序列，求给定观测序列条件概率 $\Pr(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$. 即给定观测序列，求最有可能对应的状态序列。
- 近似算法与维特比算法(Viterbi)

(1)近似算法

近似算法的思想是：在每个时刻 t 选择在该时刻最有可能出现的状态 i_t^* , 从而得到一个状态序列 $I^* = (i_1^*, \dots, i_T^*)$, 将他们作为预测结果

- 给定HMM模型 λ 和观测序列 O , 在时刻 t 处于状态 q_i 的概率 $\gamma_t(i)$ (这个是可以计算出来的, 式子我就不列了)
- 在每一个时刻 t 最有可能的状态 i_t^* 是：

$$i_t^* = \operatorname{argmax}_{1 \leq i \leq N} [\gamma_t(i)], t = 1, 2, \dots, T$$

从而得到状态序列 I^*

- 特点：
 - 计算简单
 - 不能保证预测的状态序列整体是最有可能的状态序列，因为预测的状态序列可能有实际不发生的部分
 - 尽管如此，近似算法仍有用

(2)维特比算法

威特比算法实际上是用动态规划解隐马尔可夫模型的预测问题，既用动态规划求概率最大路径(最优路径)，一条路径就对应了一个状态序列

最优路径的意思：如果最优路径在时刻 t 通过节点 i_t^* , 那么这一路径从节点 i_t^* 到终点 i_T^* 的部分路径，在所有可能的部分路径中是最优的。

这样我们就可以递归的计算 t 时刻状态为 i 各条部分路径的最大概率。这样时刻 $t = T$ 的最大概率即为最优路径的概率 P^* , 最优路径的终结点 i_T^* 也同时得到。

之后，为了找出最优路径的各个节点，从终结点 i_T^* 开始，由后向前逐步求得节点，得到最优路径

以上就是维特比算法的过程

引入两个变量 δ 和 ψ .

定义在时刻 t 状态为 i 的所有单个路径中概率最大值：

$$\delta_t(i) = \max_{i_1, \dots, i_{t-1}} \Pr(i_t = i, i_{t-1}, \dots, i_1, o_1, \dots, o_t | \lambda), i = 1, 2, \dots, N$$

很容易的得到 δ 的递推公式

$$\delta_{t+1}(i) = \max_{1 \leq j \leq N} [\delta_t(j) a_{ji}] b_i(o_{t+1})$$

定义在 t 时刻状态为 i 的所有单个路径 (i_1, \dots, i_{t-1}, i) 中概率最大的路径的第 $t-1$ 个节点为

$$\psi_t(i) = \operatorname{argmax}_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}]$$

维特比算法：

输入：HMM模型和观测

输出：最优路径 $I^* = (i_1^*, \dots, i_T^*)$

(1)初始化 $\delta_1(i) = \pi_i b_i(o_1); \psi_1(i) = 0$

(2)递推. $\delta_t(i); \psi_t(i)$

(3)终止 $P^* = \max_{1 \leq i \leq N} \delta_T(i); i_T^* = \operatorname{argmax}_{1 \leq i \leq N} [\delta_T(i)]$

(4)最优路径回溯. 对 $t = T - 1, T - 2, \dots, 1$

$$i_t^* = \psi_{t+1}(i_{t+1}^*)$$

求得最优路径 $I^* = (i_1^*, \dots, i_T^*)$

3.HMM代码实现2


```

def EM(self, observation, criterion=0.05):
    """EM算法进行参数学习"""
    n_state = self.A.shape[0]
    n_sample = len(observation)
    done = 1
    while done:
        Alpha = self.forward(observation)
        Beta = self.backward(observation)
        xi = np.zeros((n_state, n_state, n_sample-1))
        gamma = np.zeros((n_state, n_sample))
        for t in range(n_sample-1):
            denom = np.sum(np.dot(Alpha[:, t].T, self.A) * self.B[:,
                sum_gamma1 = np.sum(Alpha[:, t] * Beta[:, t])
            for i in range(n_state):
                numer = Alpha[i, t] * self.A[i, :] * self.B[:, observation[t]]
                xi[i, :, t] = numer/denom
            gamma[i, t] = Alpha[i, t] * Beta[i, t] / sum_gamma1
        last_col = Alpha[:, n_sample-1].T * Beta[:, n_sample-1]
        gamma[:, n_sample-1] = last_col / np.sum(last_col)
        # 更新参数
        n_pi = gamma[:, 0]
        n_A = np.sum(xi, 2) / np.sum(gamma[:, :, -1], 1)
        n_B = np.copy(self.B)
        num_level = self.B.shape[1]
        sum_gamma = 0
        a = 0
        for lev in range(num_level):

```

```

def viterbi(self, obs_seq):
    """viterbi算法预测状态序列"""
    N = self.A.shape[0]
    T = len(obs_seq)
    P = np.zeros((N, T))
    prev_point = np.zeros((N, T))
    prev_point[:, 0] = 0
    P[:, 0] = self.pi * self.B[:, obs_seq[0]]
    for t in range(1, T):
        for n in range(N):
            P[n, t] = np.max(P[:, t - 1] * self.A[:, n]) * self.B[n, obs_seq[t]]
            prev_point[n, t] = np.argmax(P[:, t - 1] * self.A[:, n])
    return P, prev_point

```

```
def build_path(self, obs_seq):  
    """return the optimal path"""  
    P, prev_point = self.viterbi(obs_seq)  
    T = len(obs_seq)  
    opt_path = np.zeros(T)  
    last_state = np.argmax(P[:, T-1])  
    opt_path[T-1] = last_state  
    for t in reversed(range(T-1)):  
        opt_path[t] = prev_point[int(opt_path[t+1]), t+1]  
    last_path = reversed(opt_path)  
    return last_path
```

4.后退，我要实现一个GMM-HMM语音识别系统

- 放松一下: 看看我的偶像
- 愉快的读paper
- GMM-HMM语音识别系统
- 其他语音识别框架

放松一下: 看看我的偶像

愉快的读paper

请看：Single Word Speech Recognition using Hidden Markov Models with Gaussian Mixture emissions

GMM-HMM语音识别系统

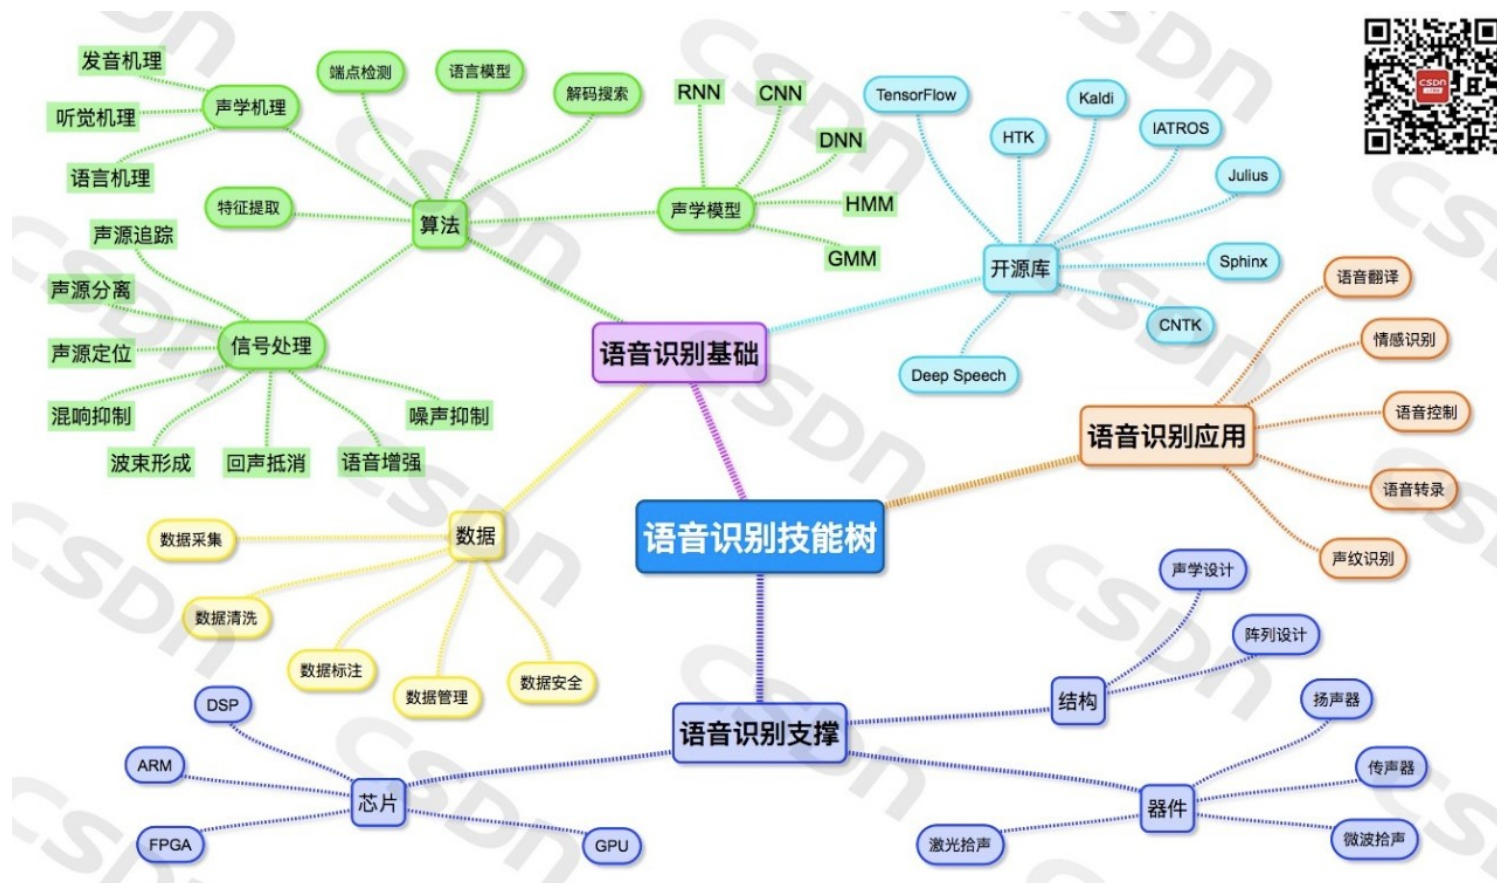
基于这篇paper,复现他GMM_HMM模型实现单个词的语音识别¹

[1].代码我已打印，想索取代码可问徐静询要

其他语音识别框架

- 常用的语言模型
 - 基于GMM-HMM
 - 基于DNN-HMM
- 常用的框架
 - kaldi
 - htk

我们还需要这些技能



5.参考文献

[1]. 机器学习[M],周志华

[2]. 统计学习方法[M],李航

[3]. 解析深度学习语音识别实践[M],俞凯, 钱彦旻

[4]. 深度学习导论及案例分析[M],李玉鑑, 张婷

[5]. Single Word Speech Recognition using Hidden Markov Models with Gaussian Mixture emissions[J],Ronak Panchal, Jayaram Kuchibhotla

问题讨论

1. HMM的3个基本问题

2. 第一节中HMM模型的例子

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}; B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}; \pi = (0.2, 0.4, 0.4)^T$$

已知观测序列 $O = (\text{红}, \text{白}, \text{红})$, 试求最优状态序列, 即最优路径 I^*



Thanks For Your Attention!